LỜI CẢM ƠN

Nhóm chúng em xin cảm ơn các thầy cô đã hướng dẫn và cung cấp kiến thức nền tảng về Deep Learning trong suốt học phần. Báo cáo được thực hiện trên tinh thần trung thực học thuật: mọi số liệu đều đến từ các lần chạy thực tế, mọi kết luận đều giới hạn trong phạm vi thí nghiệm đã thực hiện.

DANH MỤC TỪ VIẾT TẮT

Viết tắt	Giải thích
MLP	Multi-Layer Perceptron (mạng nơ-ron nhiều lớp kết nối đầy đủ)
ReLU	Rectified Linear Unit
SGD	Stochastic Gradient Descent
RMS	Root Mean Square
VJP	Vector–Jacobian Product
Var	Variance (phương sai)
NaN	Not a Number

MỤC LỤC

LỜI MỞ ĐẦU **1**

1 CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN **3**

1.1 Bài toán huấn luyện mạng nơ-ron 3

1.2 Chain rule và Jacobian 3

1.3 Backpropagation 3

1.4 Vanishing và exploding gradient 3

1.5 Khởi tạo tham số 4

1.6 Nghiên cứu liên quan và khoảng trống 4

2 THIẾT KẾ THỰC NGHIỆM **5**

2.1 Dữ liệu 5

2.2 Kiến trúc và huấn luyện 5

2.3 Biến và chỉ số 5

2.4 Giao thức 5

3 TRIỂN KHAI VÀ KẾT QUẢ **6**

3.1 Triển khai 6

3.2 Kết quả tại khởi tạo 6

3.3 Quỹ đạo huấn luyện 7

3.4 Xavier so với He 8

3.5 Độ sâu 8

3.6 Thảo luận 8

KẾT LUẬN **9**

TÀI LIỆU THAM KHẢO **10**

PHỤ LỤC A. Mã nguồn trích dẫn **12**

PHỤ LỤC B. Lệnh tái lập kết quả **13**

DANH MỤC BẢNG

2.1 Thiết lập thực nghiệm cố định. 5

3.1 Kết quả tại khởi tạo và test accuracy sau 15 epoch (seed 42). 6

DANH MỤC HÌNH

3.1 Gradient RMS ($\log_{10}$) theo lớp và cách khởi tạo, đo tại khởi tạo trên một batch. 6
3.2 Activation variance tại khởi tạo theo lớp (forward pass), một batch, trước mọi cập nhật. 7
3.3 Validation accuracy theo epoch cho năm cách khởi tạo cùng kiến trúc. . . . 7
3.4 Gradient RMS lớp 1 tại khởi tạo theo độ sâu, cho Random, Xavier và He. 8

LỜI MỞ ĐẦU

1. Bối cảnh và tính cấp thiết

Huấn luyện mạng nơ-ron là bài toán tối ưu hoá tham số θ theo hàm mất mát $L(\theta)$. Hai câu hỏi nền tảng quyết định việc mạng có học được hay không: gradient $\nabla_\theta L$ được tính thế nào khi mạng có hàng triệu tham số, và tham số nên được khởi tạo ở giá trị nào. Hai câu hỏi này liên quan trực tiếp đến hiện tượng vanishing và exploding gradient, vốn là rào cản lớn khi huấn luyện mạng sâu.

2. Vấn đề nghiên cứu

Backpropagation là ứng dụng có hệ thống của chain rule, nhưng nó chỉ tính gradient. Gradient đi qua nhiều lớp là tích của nhiều Jacobian, và scale ban đầu của tham số quyết định tín hiệu có co lại, phình ra hay được giữ ổn định hay không. Vấn đề nghiên cứu: *khởi tạo tham số ảnh hưởng thế nào đến lan truyền gradient và khả năng học của mạng sâu?*

3. Câu hỏi nghiên cứu

- **RQ1.** Backpropagation tính gradient như thế nào, và vì sao gradient ở lớp đầu có thể vanish hoặc explode?
- **RQ2.** Cách khởi tạo weight (Zero, Random nhỏ, Random lớn, Xavier, He) gây ra các thất bại nào trong cùng một kiến trúc?
- **RQ3.** Xavier và He có vượt trội nhau một cách có ý nghĩa thống kê trong thiết lập này không, và gradient ổn định có đảm bảo generalization không?

4. Mục tiêu và nhiệm vụ

Mục tiêu: trình bày backpropagation và khởi tạo tham số một cách có chứng cứ, bằng cả giải thích toán học và thực nghiệm nhỏ trên Fashion-MNIST. Nhiệm vụ: (i) xây dựng backpropagation thủ công và kiểm tra bằng autograd và sai phân hữu hạn; (ii) đo gradient và activation variance tại khởi tạo cho năm cách khởi tạo; (iii) đánh giá huấn luyện, độ sâu và số seed.

5. Đối tượng và phạm vi

Đối tượng: gradient, activation và quỹ đạo huấn luyện của mạng MLP với activation ReLU. Phạm vi: MLP $784 \to 128 \times 10 \to 10$, Fashion-MNIST subset 5.000/1.000/2.000, SGD cố định $\eta = 0{,}05$, 15 epoch, seed 42 (và 5 seed cho Xavier, He). Không khảo sát CNN, Transformer, Adam hay BatchNorm.

6. Phương pháp nghiên cứu

- **Nghiên cứu tài liệu** về backpropagation, chain rule và khởi tạo tham số.
- **Thực nghiệm có kiểm soát**: chỉ đổi cách khởi tạo weight, giữ mọi yếu tố khác cố định.
- **Đo lường**: gradient RMS, activation variance tại khởi tạo; train/validation/test loss và accuracy theo epoch.

7. Bố cục báo cáo

Chương 1 trình bày cơ sở lý thuyết và nghiên cứu liên quan. Chương 2 mô tả thiết kế thực nghiệm. Chương 3 trình bày triển khai và kết quả. Phần Kết luận trả lời các câu hỏi nghiên cứu, nêu hạn chế và hướng phát triển. Phụ lục chứa mã nguồn trích dẫn.

Chương 1

CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN

1.1 Bài toán huấn luyện mạng nơ-ron

Với mạng f_θ, dữ liệu (x, y) và hàm mất mát L, huấn luyện là tìm $\theta^* = \arg\min_\theta \mathbb{E}[L(f_\theta(x), y)]$. Gradient descent cập nhật $\theta_{\text{new}} = \theta_{\text{old}} - \eta \nabla_\theta L$. Gradient là vector các đạo hàm riêng và chỉ hướng tăng nhanh nhất của L; dấu trừ đưa tham số đi ngược hướng đó.

1.2 Chain rule và Jacobian

Với đồ thị tính toán $z = g(u)$, $L = f(z)$: $\partial L/\partial u = (\partial L/\partial z)(\partial z/\partial u)$. Khi biến là vector, mỗi phép biến đổi có một Jacobian. Gradient qua nhiều lớp là tích của các Jacobian này.

1.3 Backpropagation

Forward pass tính đầu ra và lưu các giá trị trung gian. Backward pass nhận $\delta^{(l)} = \partial L/\partial h^{(l)}$ và tính $\delta^{(l-1)} = J_l^\top \delta^{(l)}$, $\partial L/\partial W^{(l)} = \delta^{(l)}(h^{(l-1)})^\top$. Backprop không lập ma trận Jacobian đầy đủ mà chỉ thực hiện tích vector–Jacobian (VJP); autograd của PyTorch làm việc này cho từng nút. Backprop chỉ tính gradient; optimizer mới cập nhật tham số.

1.4 Vanishing và exploding gradient

Nếu mỗi lớp co norm tín hiệu theo hệ số 0,5, sau 20 lớp hệ số là $0{,}5^{20} \approx 9{,}5 \times 10^{-7}$ (vanishing). Nếu khuếch đại theo hệ số 1,5, sau 20 lớp hệ số khoảng 3×10^3 (exploding). Với sigmoid và tanh, bão hoà làm đạo hàm về 0. Với ReLU, miền âm làm second moment $\mathbb{E}[a^2]$ giảm xấp xỉ một nửa mỗi lớp.

1.5 Khởi tạo tham số

- **Zero:** các neuron cùng lớp giống hệt nhau; đây là thất bại đối xứng (*failure to break symmetry*). Vấn đề nằm ở weight; bias khởi tạo 0 vẫn chấp nhận được.
- **Random** $\mathcal{N}(0, \sigma^2)$: σ nhỏ dẫn tới vanishing; σ lớn dẫn tới exploding.
- **Xavier/Glorot** (Normal): $\mathrm{Var}(W) = 2/(n_{\text{in}} + n_{\text{out}})$, giả định activation tuyến tính quanh 0 hoặc đối xứng quanh 0 (như tanh). Mục tiêu là giúp duy trì variance, không phải đảm bảo tuyệt đối.
- **He/Kaiming**: $\mathrm{Var}(W) = 2/n_{\text{in}}$, bù việc ReLU làm giảm $\mathbb{E}[a^2]$. Đại lượng được điều chỉnh là $\mathbb{E}[a^2]$, không phải variance thuần vì ReLU không zero-centered.

1.6 Nghiên cứu liên quan và khoảng trống

Các nghiên cứu nền tảng gồm Rumelhart và cộng sự về backpropagation [1], LeCun và cộng sự về các mẹo huấn luyện [2], Glorot và Bengio về Xavier [3], và He và cộng sự về He initialization cho ReLU [4]. Phần lớn công trình này chứng minh lý thuyết hoặc đo trên benchmark lớn. Báo cáo này đóng góp một thí nghiệm kiểm soát chặt, cô lập đúng biến khởi tạo, trên mạng 10 lớp, với đo gradient và activation variance tại khởi tạo.

Chương 2

THIẾT KẾ THỰC NGHIỆM

2.1 Dữ liệu

Fashion-MNIST [6] với subset 5.000 train, 1.000 validation và 2.000 test. Ảnh 28×28 được làm phẳng thành 784 chiều và chuẩn hoá theo mean/std tính trên tập train.

2.2 Kiến trúc và huấn luyện

Thành phần	Giá trị
Kiến trúc	MLP $784 \to 128 \times 10 \to 10$, ReLU
Optimizer	SGD thuần, $\eta = 0{,}05$, batch 128, 15 epoch, không momentum, không scheduler
Loss	CrossEntropy
Bias	Khởi tạo 0 trong mọi cấu hình
Seed	42; 5 seed $\{42, \ldots, 46\}$ cho Xavier và He
Biến duy nhất	Cách khởi tạo weight

Bảng 2.1: Thiết lập thực nghiệm cố định.

2.3 Biến và chỉ số

Gradient RMS: $\sqrt{\text{mean}(g^2)}$ trên một batch đầu tiên, đo trước mọi cập nhật. Activation variance đo tương tự. Train/validation/test loss và accuracy đo theo epoch; test chỉ dùng đánh giá cuối.

2.4 Giao thức

Năm cấu hình khởi tạo chạy cùng seed. Xavier và He chạy thêm 5 seed để ước lượng biến thiên. Thí nghiệm độ sâu so sánh Random, Xavier và He ở nhiều độ sâu với số epoch ít hơn, nên số tuyệt đối chỉ dùng để so sánh tương đối.

Chương 3

TRIỂN KHAI VÀ KẾT QUẢ

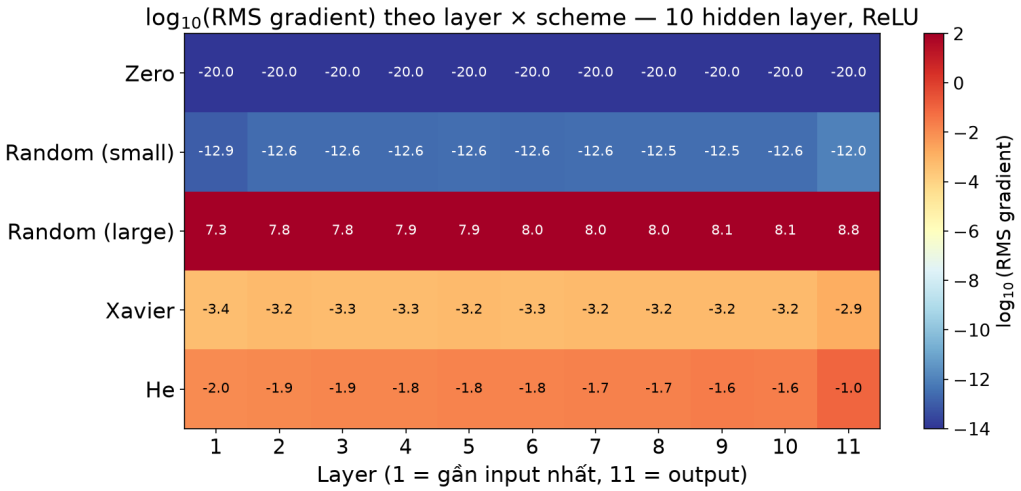
3.1 Triển khai

Backpropagation được cài đặt thủ công bằng NumPy và được kiểm tra bằng PyTorch autograd và sai phân hữu hạn; sai số tối đa ở mức 10^{-9}. Phần huấn luyện dùng PyTorch với seed cố định.

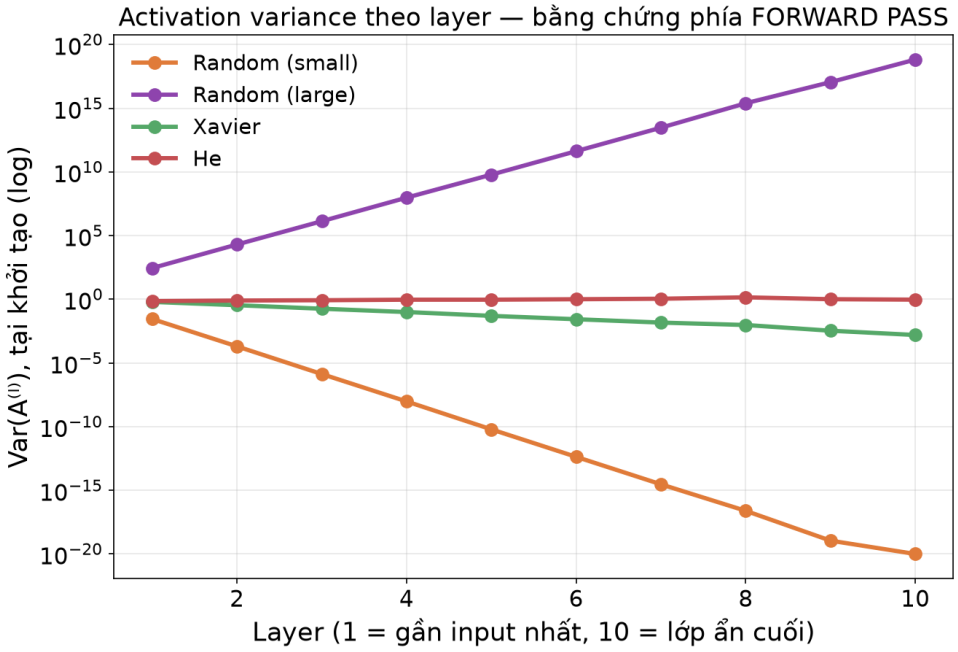
3.2 Kết quả tại khởi tạo

Khởi tạo	Gradient RMS lớp 1	Test accuracy	Hành vi
Zero	0	10,0%	Thất bại đối xứng
Random nhỏ ($\sigma = 0{,}01$)	$1{,}1 \times 10^{-13}$	10,0%	Vanishing
Random lớn ($\sigma = 1{,}0$)	$1{,}9 \times 10^{7}$	10,0% (loss NaN)	Exploding $\rightarrow$ NaN
Xavier (Normal)	$4{,}4 \times 10^{-4}$	68,2%	Không vanish/explode rõ rệt
He (Kaiming)	$1{,}1 \times 10^{-2}$	67,4%	Không vanish/explode rõ rệt

Bảng 3.1: Kết quả tại khởi tạo và test accuracy sau 15 epoch (seed 42).

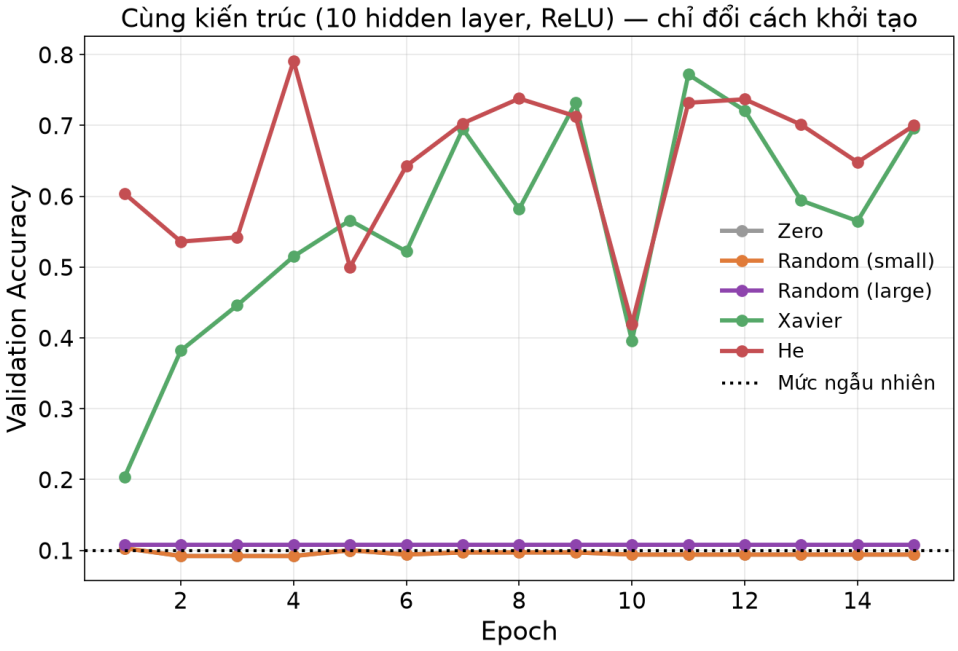


Hình 3.1: Gradient RMS ($\log_{10}$) theo lớp và cách khởi tạo, đo tại khởi tạo trên một batch.



Hình 3.2: Activation variance tại khởi tạo theo lớp (forward pass), một batch, trước mọi cập nhật.

3.3 Quỹ đạo huấn luyện



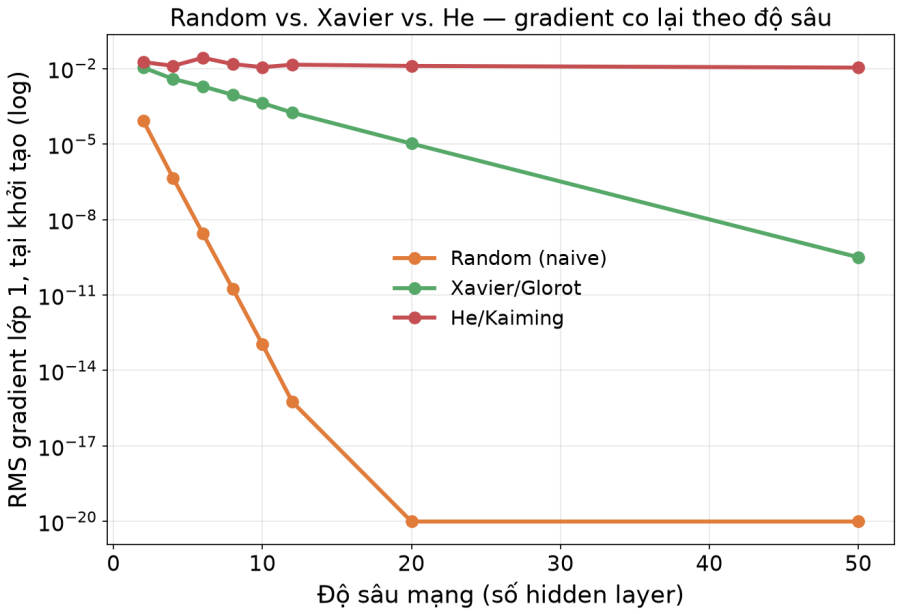
Hình 3.3: Validation accuracy theo epoch cho năm cách khởi tạo cùng kiến trúc.

Zero và Random nhỏ dừng ở 10%. Random lớn không hội tụ. Xavier và He đạt khoảng 67–68% test accuracy. Dao động validation accuracy đáng kể vì dùng vanilla SGD với $\eta = 0{,}05$, không momentum và không scheduler, trên mạng 10 tầng.

3.4 Xavier so với He

Trên 5 seed, test accuracy trung bình ± độ lệch chuẩn là 69,1% ± 4,7pp (Xavier) và 70,5% ± 5,7pp (He). Khoảng mean ± 1 std chồng lấn đáng kể. Gradient RMS lớp 1 của He lớn hơn Xavier khoảng 35 lần, nhất quán trên mọi seed, nhưng gradient lớn hơn không đồng nghĩa với kết quả tốt hơn. Với số seed hiện tại, chưa đủ cơ sở xếp hạng Xavier và He.

3.5 Độ sâu



Hình 3.4: Gradient RMS lớp 1 tại khởi tạo theo độ sâu, cho Random, Xavier và He.

Khi độ sâu tăng, gradient của Random và Xavier suy giảm; He giữ scale tốt hơn trong thiết lập này. Ổn định gradient không đồng nghĩa với generalization tốt: ở độ sâu 12, He có train loss thấp nhưng test loss cao. Kết luận chỉ đúng với MLP, ReLU, Fashion-MNIST và SGD đã thử.

3.6 Thảo luận

Ba thất bại ban đầu được phân biệt rõ: Zero-init thất bại vì đối xứng, Random nhỏ vì vanishing, Random lớn vì exploding; NaN chỉ là triệu chứng của mất ổn định số học. Trong mạng rất sâu (trên khoảng 50 lớp), initialization thường cần kết hợp với Residual connections và Normalization (LayerNorm, BatchNorm) để kiểm soát gradient flow; báo cáo này không thực nghiệm các kỹ thuật đó.

KẾT LUẬN

1. Kết quả đạt được

1. Backpropagation được trình bày như chain rule áp dụng ngược qua đồ thị tính toán; gradient descent là quy tắc cập nhật dùng gradient đó.
2. Trong thiết lập đã thử, zero-init gây thất bại đối xứng, random nhỏ gây vanishing, random lớn gây exploding.
3. Xavier và He tránh được các thất bại trên trong thiết lập này.

2. Trả lời câu hỏi nghiên cứu

RQ1 được trả lời bằng phần lý thuyết và kiểm tra backprop. **RQ2** được trả lời bằng bảng kết quả tại khởi tạo. **RQ3**: chưa đủ cơ sở xếp hạng Xavier và He; gradient ổn định không đảm bảo generalization tốt.

3. Hạn chế

- Dataset là subset nhỏ, chỉ một kiến trúc MLP với ReLU.
- Optimizer cố định (SGD, $\eta = 0{,}05$), không khảo sát tương tác với learning rate hay optimizer khác.
- Gradient và activation variance đo tại khởi tạo trên một batch.
- Xavier và He có 5 seed; Zero, Random nhỏ và Random lớn chỉ có 1 seed.
- Thí nghiệm độ sâu dùng số epoch ít hơn; số tuyệt đối có thể khác.

4. Hướng phát triển

Chạy nhiều seed hơn để đánh giá khác biệt Xavier và He; thử thêm Adam và BatchNorm; kết hợp initialization với Residual connections trên mạng rất sâu.

TÀI LIỆU THAM KHẢO

TÀI LIỆU THAM KHẢO

[1] D. E. Rumelhart, G. E. Hinton, R. J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.

[2] Y. LeCun, L. Bottou, G. B. Orr, K.-R. Müller. Efficient BackProp. In *Neural Networks: Tricks of the Trade*, 1998/2012.

[3] X. Glorot, Y. Bengio. Understanding the difficulty of training deep feedforward neural networks. *AISTATS*, 2010.

[4] K. He, X. Zhang, S. Ren, J. Sun. Delving Deep into Rectifiers. *ICCV*, 2015. arXiv:1502.01852.

[5] I. Goodfellow, Y. Bengio, A. Courville. *Deep Learning*. MIT Press, 2016.

[6] H. Xiao, K. Rasul, R. Vollgraf. Fashion-MNIST. arXiv:1708.07747, 2017.

[7] A. Paszke et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. *NeurIPS*, 2019.

PHỤ LỤC A. MÃ NGUỒN TRÍCH DẪN

Listing 1: Tính gradient RMS tại khởi tạo (trích, experiments/run_deep_demo.py)

```
loss = criterion(model(x), y)
loss.backward()
grad_rms = [p.grad.pow(2).mean().sqrt().item()
          for n, p in model.named_parameters() if "weight" in n]
```

PHỤ LỤC B. LỆNH TÁI LẬP KẾT QUẢ

```
python experiments/run_manual_backprop.py
python experiments/run_gradient_check.py
python experiments/run_deep_demo.py
python experiments/run_multiseed.py
python experiments/run_depth_experiment_v2.py
```